



Universidade Federal da Paraíba

Coordenação do Curso de Ciência de Dados e
Inteligência Artificial



Modelo de Aprendizagem Linear II

Regressão Logística

Prof. Gilberto Farias

Roteiro


- O modelo de Regressão Logística
- Medida de Erro
- Algoritmo de Aprendizagem

Terceiro modelo linear – Regressão Logística

$$s = \sum_{i=0}^d w_i x_i$$


classificação linear (*perceptron*)

$$h(x) = \text{sign}(s)$$




regressão linear

$$h(x) = s$$



regressão logística


$$h(x) = \theta(s)$$



Função logística θ

A fórmula

$$\theta(s) = \frac{e^s}{1 + e^s}$$



limiar suave : incerteza

Interpretação probabilística

$h(x) = \theta(s)$ é interpretado como uma probabilidade

Exemplo. Predição de ataque cardíaco

Entrada x : nível de colesterol, idade, peso, .. Etc.

$\theta(s)$: probabilidade de ataque cardíaco

O valor $s = w^T x$ “pontuação de risco”

Probabilidade genuína

Os dados (\mathbf{x}, y) com y binário (± 1) são gerados por uma função de ruído alvo:

$$P(y|\mathbf{x}) = \begin{cases} f(\mathbf{x}) & \text{para } y = +1; \\ 1 - f(\mathbf{x}) & \text{para } y = -1. \end{cases}$$

O alvo $f: \mathbb{R}^d \rightarrow [0,1]$ é a probabilidade

$$\text{Aprender } g(\mathbf{x}) = \theta(\mathbf{w}^T \mathbf{x}) \approx f(\mathbf{x})$$

Medida de erro para a Regressão Logística

Uso da verossimilhança


Para cada (x, y) , y é gerado pela probabilidade $f(x)$

Medida de erro plausível baseada em verossimilhança:

Se $h = f$ quão provável se obtém y de x


Probabilidade x Verossimilhança

$\theta = (\sigma, \mu)$



$$P(30 \leq x \leq 34 | \theta) = ??$$

$\theta = ??$



$L(\theta | x)$: estimadores da distribuição de probabilidades

$$P(x | \theta) = L(\theta | x)$$

Uso da verossimilhança

Para cada (x, y) , y é gerado pela probabilidade $f(x)$

Medida de erro plausível baseada em verossimilhança:

Se $h = f$ quão provável se obtém y de x

$$P(y|x) = \begin{cases} f(x) & \text{para } y = +1; \\ 1 - f(x) & \text{para } y = -1. \end{cases}$$

Uso da verossimilhança

Para cada (x, y) , y é gerado pela probabilidade $f(x)$

Medida de erro plausível baseada em verossimilhança:


Se $h = f$ quão provável se obtém y de x

$$P(y|x) = \begin{cases} h(x) & \text{para } y = +1; \\ 1 - h(x) & \text{para } y = -1. \end{cases}$$

Fórmula para a verossimilhança

$$P(y|x) = \begin{cases} h(x) & \text{para } y = +1; \\ 1 - h(x) & \text{para } y = -1. \end{cases}$$

Substituindo $h(x) = \theta(w^T x)$



notando que $\theta(-s) = 1 - \theta(s)$

Simplificando temos: $P(y|x) = \theta(yw^T x)$

Verossimilhança de $D = (x_1, y_1), \dots, (x_N, y_N)$, gerados independentemente, é:

$$\prod_{n=1}^N P(y_n|x_n) = \prod_{n=1}^N \theta(y_n \textcolor{red}{w}^T x_n)$$

Maximizando a verossimilhança

Maximize

$$\prod_{n=1}^N \theta(y_n \mathbf{w}^T \mathbf{x}_n)$$

Maximizando a verossimilhança

Maximize

$$\ln \left(\prod_{n=1}^N \theta(y_n \mathbf{w}^T \mathbf{x}_n) \right)$$

\ln : função monótona

Maximizando a verossimilhança

Maximize

$$\frac{1}{N} \ln \left(\prod_{n=1}^N \theta(y_n \mathbf{w}^T \mathbf{x}_n) \right)$$

Maximizando a verossimilhança

Minimize

$$-\frac{1}{N} \ln \left(\prod_{n=1}^N \theta(y_n \mathbf{w}^T x_n) \right)$$

$$= \frac{1}{N} \sum_{n=1}^N \ln \left(\frac{1}{\theta(y_n \mathbf{w}^T x_n)} \right)$$

$$\left[\theta(s) = \frac{1}{1 + e^{-s}} \right]$$

$$E_{in} = \frac{1}{N} \sum_{n=1}^N \ln \left(1 + e^{-y_n \mathbf{w}^T x_n} \right)$$

Maximizando a verossimilhança

Minimize

$$-\frac{1}{N} \ln \left(\prod_{n=1}^N \theta(y_n \mathbf{w}^T x_n) \right)$$

$$= \frac{1}{N} \sum_{n=1}^N \ln \left(\frac{1}{\theta(y_n \mathbf{w}^T x_n)} \right)$$

$$\left[\theta(s) = \frac{1}{1 + e^{-s}} \right]$$

$$E_{in} = \frac{1}{N} \sum_{n=1}^N \underbrace{\ln \left(1 + e^{-y_n \mathbf{w}^T x_n} \right)}_{e(h(x_n), y_n)}$$

erro de “entropia cruzada”

Como minimizar E_{in}

Para regressão logística,


$$E_{in}(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N \ln \left(1 + e^{-y_n \mathbf{w}^T x_n} \right) \longleftarrow \text{solução iterativa}$$

Para regressão linear,

$$E_{in}(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N (\mathbf{w}^T x_n - y_n)^2 \longleftarrow \text{solução fechada}$$

Método do Gradiente Descendente

Método geral de otimização não linear




Método iterativo – Gradiente descendente

Inicia com $w(0)$; avança na direção de maior inclinação

Passos de tamanho fixo: $w(1) = w(0) - \eta \hat{v}$


Qual a direção de \hat{v} ?

$$\hat{v} = \nabla E_{in}(w(0))$$




Qual o tamanho do passo?


Como η afeta o algoritmo:



η pequeno



η grande



η na medida

η deve variar junto com a inclinação da superfície $\longrightarrow \eta \nabla E_{in}(w(0))$
comportamento da derivada

Algoritmo da Regressão Logística

1. Inicialize os pesos no tempo $t = 0$ para $w(0)$;
2. *Para $t = 0, 1, 2, \dots$ faça*
3. *Compute o gradiente*

$$g_t = -\frac{1}{N} \sum_{n=1}^N \frac{y_n x_n}{1 + e^{y_n w^T(t) x_n}}$$

4. *Atualize os pesos $w(t + 1) = w(t) - \eta g_t$;*
5. *Itere para o próximo passo enquanto não atingir a
 condição de parada;*
6. *Retorne o peso final w .*

Configurações do Algoritmo

- Inicialização das variáveis:
 - $\eta = 0.1$ (bons resultados na prática)
 - $w(0) = 0$ ou inicia com valor aleatório
- Condição de parada:
 - O ideal seria $\|g_t\| = 0$ (ponto mínimo)
 - Limitar a quantidade de iterações;
 - Definir um limiar para o valor de $\|g_t\|$.

Resumo dos Modelos Lineares

